O tema refinado seria:

“Abordagens baseadas em grafos em Retrieval-Augmented Generation: um mapeamento sistemático da literatura”

O objetivo principal do trabalho será identificar, classificar e analisar as principais técnicas que utilizam grafos em sistemas de Retrieval-Augmented Generation, buscando compreender como essas abordagens estruturam o conhecimento, realizam a recuperação de informação, apoiam tarefas que exigem relações entre entidades e são aplicadas em tarefas que envolvem raciocínio multi-hop, rastreabilidade das evidências ou melhoria da contextualização das respostas.

A entrega principal pretendida será:

- uma classificação das abordagens encontradas;
- uma análise qualitativa das estratégias utilizadas;
- a identificação de limitações, tendências e lacunas de pesquisa;
- a sistematização de possíveis caminhos para investigações futuras.

Não pretendemos realizar medições experimentais próprias nem desenvolver um protótipo. As métricas utilizadas nos estudos, ou métricas relacionadas à factualidade, serão apenas catalogadas e analisadas qualitativamente com base no que for reportado nos artigos selecionados.

Como trabalhos primários iniciais, selecionamos os seguintes artigos:

1. From Local to Global: A Graph RAG Approach to Query-Focused Summarization

Este trabalho será utilizado como uma das principais referências por apresentar uma abordagem GraphRAG voltada à sumarização orientada por consulta, com construção de grafo derivado de texto e uso de resumos de comunidades para apoiar respostas globais.

2. HippoRAG: Neurobiologically Inspired Long-Term Memory for Large Language Models

Este artigo será considerado por representar uma abordagem de recuperação baseada em grafos com uso de difusão, como Personalized PageRank, para priorizar vizinhanças relevantes no grafo e apoiar raciocínio multi-hop.

3. GRAG: Graph Retrieval-Augmented Generation

Este trabalho será usado como referência por explorar a recuperação de subgrafos relevantes, preservando aspectos semânticos e topológicos para apoiar a geração por modelos de linguagem.

Esses três artigos não serão tratados como um corpus fechado, mas como base conceitual inicial. A seleção final dos estudos será conduzida posteriormente por meio de um protocolo sistemático, com definição de strings de busca, bases consultadas, critérios de inclusão e exclusão, e registro do processo de filtragem conforme a metodologia PRISMA.

Classificação das abordagens encontradas (Taxonomia): Criar um "mapa" ou uma árvore de classificação. Por exemplo, dividir os trabalhos entre aqueles que usam LLMs para extrair o grafo de forma pontual no momento de ingestão (como o GraphRAG da Microsoft) e aqueles que usam bases de conhecimento em grafos já pré-existentes. Também pode-se classificar as técnicas de recuperação (busca em nós vs. busca por caminhos/arestas). O objetivo é que seja possível entender todas as "famílias" de GraphRAG que existem ao ler o documento produzido.

A**nálise qualitativa das estratégias utilizadas:** Discutir porquê e como as abordagens funcionam. Por exemplo: "O artigo X demonstrou que usar *PageRank* para recuperar vizinhanças reduziu as alucinações em X%, sugerindo que manter a topologia do grafo no prompt ajuda o LLM a rastrear as evidências". A interpretações dos dados lidos.

A identificação de limitações, tendências e lacunas de pesquisa: Apontar os problemas que a comunidade ainda não resolveu. Exemplos clássicos: o custo altíssimo (em *tokens* e dinheiro) para extrair entidades e relações via LLM em larga escala, e a dificuldade de atualizar esses grafos em tempo real (*streaming data*). Mapear "o que falta inventar".

A sistematização de possíveis caminhos para investigações futuras: Listar sugestões práticas do que futuros pesquisadores devem investigar.

Bases de busca:

IEEE Xplorer

SpringerLink

ScienceDirect

Web of Science

Arxiv

Strings de busca:

Critérios de inclusão:

Cristérios de exclusão: