Proposta de MVP: GraphRAG para Apoio à Tomada de Decisão

Documento para validação do grupo Status: aguardando aprovação de todos os integrantes

---

1. Por que esse MVP

O nosso próprio protocolo já define o que o artefato precisa ser. O **CI7** diz que o estudo deve gerar "alguma recomendação, priorização ou avaliação que ajude alguém a decidir algo, não apenas responder um dado". O **CE8** diz o oposto pelo avesso.

Ou seja: se o nosso MVP não passaria no CI7 que nós mesmos escrevemos, ele está errado.

Isso não é detalhe. É o argumento de coerência metodológica que sustenta o artefato na defesa, porque o MVP vira consequência direta do mapeamento e não um apêndice colado no fim.

Reforçando esse recorte, o CE8 sozinho eliminou 25 estudos, quase metade das nossas exclusões. Isso mostra que a maior parte da literatura de GraphRAG faz recuperação factual, não apoio à decisão. É uma lacuna real e justifica tanto o tema quanto o MVP.

---

2. O que o sistema faz

Entrada: uma situação decisória do domínio, não uma pergunta factual.

- Não é: "qual o valor de X?"
- É: "dadas estas condições, qual alternativa devo seguir?"

Processamento: grafo de conhecimento construído a partir do corpus por extração de entidades e relações com LLM. Recuperação híbrida, usando busca vetorial para encontrar o ponto de entrada no grafo e traversal para expandir o contexto relevante à decisão.

Saída (é aqui que está a nossa contribuição):

1. Alternativas ranqueadas, não uma resposta única
2. Justificativa de cada alternativa
3. Subgrafo de evidência que sustenta a recomendação
4. Incertezas e informações faltantes

O item 4 é o que quase nenhum sistema entrega e é o que separa apoio à decisão de simples geração de resposta. Quem decide precisa saber o que o sistema **não** sabe.

---

3. Avaliação

Sem avaliação o MVP vira demonstração sem resultado. O desenho é:

- **Baseline:** RAG vetorial convencional sobre o mesmo corpus

- **Conjunto de teste:** 30 a 50 situações decisórias com gabarito, validadas por alguém do domínio
- **Métricas:** as que a RQ5 levantar nos 34 estudos, mais uma métrica própria de **rastreabilidade** (proporção de afirmações da recomendação que têm caminho de evidência verificável no grafo)

A métrica de rastreabilidade é originalidade nossa, não vem de nenhum artigo.

> **Regra inegociável do experimento:** o baseline vetorial precisa usar exatamente o mesmo LLM e o mesmo modelo de embeddings do GraphRAG. Só assim a diferença medida é atribuível ao grafo, e não ao modelo. Se o baseline rodar com outro modelo, o resultado da RQ6 não vale nada.

---

4. Elo com o mapeamento

Questão de pesquisa	Como o MVP se conecta
RQ1	As técnicas apontadas como dominantes em cenários decisórios são as que implementamos
RQ2 e RQ3	Definem como construímos o grafo e como recuperamos
RQ4	Orienta a escolha do domínio do corpus
RQ5	As limitações reportadas viram as hipóteses que a avaliação testa
RQ6	É respondida diretamente pelo experimento (GraphRAG contra RAG convencional)

---

5. Infraestrutura com custo zero

Modelo e stack

Componente	Escolha	Observação
LLM	Qwen2.5 14B (Q4_K_M)	vLLM para batch, Ollama para a demo
Embeddings	BGE-m3 ou multilingual-e5-base	Local, roda em CPU se precisar
Grafo	Neo4j Community Edition	Gratuito, sem limite pro nosso tamanho
Vetorial (baseline)	FAISS ou Chroma	Escolher na primeira semana
Backend	FastAPI	Sem observação
Front	Streamlit	Poupa semanas; front bonito não é onde investir

Onde processar

A construção do grafo passa o corpus inteiro pelo modelo, chunk por chunk. Numa RTX 3060 12GB isso leva de 6 a 7 horas por passada sem otimização, e vamos reprocessar umas 5 vezes até o prompt de extração ficar bom.

Solução: Kaggle. Oferece 30 horas semanais de GPU grátis (T4 16GB) por conta. Somos 3 devs, então são 90 horas por semana sem custo. A construção do grafo é batch e não precisa de interação, então encaixa perfeitamente: rodamos no Kaggle, baixamos o grafo pronto, e a máquina local fica livre para desenvolver e demonstrar.

Três otimizações que economizam horas

1. **vLLM em vez de Ollama para o processamento em massa.** Ollama processa um chunk por vez; vLLM processa em lote e multiplica o throughput por 4 ou 5.
2. **Saída estruturada obrigatória.** Usar JSON schema ou grammar na extração de triplas. JSON quebrado significa reprocessar tudo.
3. **Testar o prompt em 20 chunks antes de rodar o corpus inteiro.** Sempre.

Custo total do projeto: R$ 0,00.

---

6. Divisão de tarefas

Time teórico (2 pessoas)

Não some depois da escrita. São vocês que leem os 34 estudos, então são a fonte de duas coisas que o MVP depende:

- **As métricas de avaliação** extraídas da RQ5. O time de dev não deve inventá-las.
- **A redação das situações decisórias** do conjunto de teste. Escrever gabarito não é tarefa de dev, é de quem entende do domínio e leu a literatura.

Também ficam com a correção dos números do PRISMA (ver seção 8) e a reescrita das motivações das RQs.

Time de desenvolvimento (3 pessoas)

Fatias com pouca dependência entre si:

Dev	Responsabilidade
Dev 1	Pipeline de ingestão e grafo: chunking, extração de entidades e relações, carga no Neo4j
Dev 2	Recuperação híbrida **e** o baseline vetorial, os dois na mesma mão, que é o que garante paridade
Dev 3	Interface, harness de avaliação e exibição do subgrafo de evidência

Destravamento: o Dev 1 começa primeiro e entrega cedo um grafo pequeno (5 a 10 documentos) só para Dev 2 e Dev 3 não ficarem parados. Contrato de interface definido na primeira semana.

---

7. Ordem de execução

1. **Semana 1.** Definir corpus e domínio. Dev 1 monta o pipeline; contrato de interface fechado com Dev 2 e 3.
2. **Semana 2.** Grafo pequeno entregue. Time teórico começa a escrever as situações decisórias.
3. **Semanas 3 e 4.** Recuperação e baseline funcionando. Construção do grafo completo rodando no Kaggle, em paralelo.
4. **Semana 5.** Harness de avaliação rodando os dois sistemas.
5. **Semana 6.** Execução final, coleta de métricas, análise.

Ajustar conforme o prazo real entre o fim da leitura de texto completo e a entrega.

> **Aviso:** a construção do grafo precisa rodar em paralelo ao desenvolvimento, não na semana da entrega. O erro clássico é descobrir na última hora que o processamento leva 30 horas.

---

8. Pendências que travam o MVP

Estas precisam de resposta antes de começarmos:

1. **Corpus.** Em qual domínio temos acesso real a documentos, sem barreira de sigilo ou licença? Volume entre 50 e 200 documentos.
2. **Validador de domínio.** Existe alguém acessível que consiga julgar se uma recomendação do sistema está certa ou errada? **Sem isso não conseguimos avaliar nada.** É a pendência mais crítica.
3. **Plano B do corpus.** Se não houver corpus real em nenhum domínio, aceitamos usar corpus público (documentação técnica aberta, base de artigos)? Perde realismo, mas destrava o projeto.

Correções no documento do TCC (independentes do MVP)

- **Os números do PRISMA não fecham.** As exclusões listadas somam 46 (6 + 11 + 2 + 2 + 25), mas reportamos 53 no total excluído. E 87 menos 46 dá 41, não 34. Há 7 estudos sem destino rastreável, e a banca pega isso.
- **Falta o N do IEEE.** Reportamos Scopus 76 e bruto 91, o que implica 15 do IEEE, mas não está escrito. Cada base precisa do seu número declarado.
- **Grafia da base:** é IEEE Xplore, não "IEE EXPLORER".
- **CE1 foi aplicado fora do que está escrito.** O critério diz "mencionam grafos ou RAG apenas de forma incidental", mas usamos para "menção incidental à decisão". Ou reescrevemos o CE1, ou realocamos esses 11 estudos para o CE8.
- **RQ4 está duplicada** ("RQ4. RQ4.") e a coluna de motivação das RQs está vazia inteira.

---

9. O que precisamos aprovar

- [ ] O desenho do MVP descrito na seção 2
- [ ] O desenho de avaliação da seção 3, incluindo a regra do mesmo modelo no baseline
- [ ] A stack e a estratégia de Kaggle da seção 5
- [ ] A divisão de tarefas da seção 6
- [ ] Quem responde cada pendência da seção 8 e até quando

Se alguém discordar de algum ponto, melhor levantar agora do que na terceira semana.