Bacharelado em Engenharia de Software



Universidade Católica do Salvador
Bacharelado em Engenharia de Software

GraphRAG para Apoio à Tomada de Decisão: Um Mapeamento Sistemático da Literatura

Salvador
2026

GraphRAG para Apoio à Tomada de Decisão: Um Mapeamento Sistemático da Literatura

Trabalho de Conclusão de Curso apresentado à Universidade Católica do Salvador como parte dos requisitos necessários para a obtenção do Título de Engenheiro de Software.
Orientador: Prof. Angela Peixoto

Universidade Católica do Salvador

Salvador
2026

GraphRAG para Apoio à Tomada de Decisão: Um Mapeamento Sistemático da Literatura

Trabalho de Conclusão de Curso apresentado à Universidade Católica do Salvador como requisito parcial para a obtenção do título de Engenheiro de Software.

Salvador, 4 de outubro de 2026

Banca Examinadora:

Prof. Angela Peixoto
Universidade Católica do Salvador
Orientador

Prof. Me. Segundo professor
Universidade Católica do Salvador

Prof. Me. Terceiro professor
Universidade Católica do Salvador

Dedico este trabalho a todos aqueles....

Agradecimentos

Agradeço primeiramente a ...

”ABC”
(Albert Einstein)

Resumo

XXXXX .

Palavras-Chave: SEU TEMA

Abstract

ESCREVA AQUI SEU RESUMO em INGLES

Keywords: 1. Programming teaching. 2. Young people’s lack of IT information. 3. Need of the IT job market.

Lista de figuras

Lista de tabelas

Lista de Siglas e Abreviaturas

API	*Application Programming Interface*
BES	Bacharelado em Engenharia de Software
CE	Critério de Exclusão
CI	Critério de Inclusão
IA	Inteligência Artificial
LLM	*Large Language Model*
LLM-MAS	*Large Language Model-based Multi-Agent System*
MVP	*Minimum Viable Product*
PICO	População, Intervenção, Comparação, Desfecho
PRISMA	*Preferred Reporting Items for Systematic Reviews and Meta-Analyses*
RAG	*Retrieval-Augmented Generation*
RQ	*Research Question* (Pergunta de Pesquisa)
SAD	Sistema de Apoio à Decisão

Sumário

1	INTRODUÇÃO	15
2	FUNDAMENTAÇÃO TEÓRICA	16
2.1	Modelos de Linguagem de Grande Escala (LLMs)	16
2.2	Retrieval-Augmented Generation (RAG)	17
2.3	Grafos e Grafos de Conhecimento	18
2.3.1	Fundamentos de teoria de grafos	18
2.3.2	Grafos de Conhecimento: definição e componentes	18
2.3.3	Construção de Grafos de Conhecimento a partir de texto	19
2.3.4	Grafos de Conhecimento como índice para recuperação aumentada	20
2.4	GraphRAG	20
2.5	Apoio à tomada de decisão	21
2.6	Trabalhos Relacionados	22

1 Introdução

Os Modelos de Linguagem de Grande Escala (LLMs) são modelos de inteligência artificial treinados para compreender e gerar respostas em linguagem natural, refletindo o rápido progresso técnico observado na área nos últimos anos (**??**). Apesar desses avanços, os LLMs apresentam limitações relevantes, como o conhecimento desatualizado adquirido durante o treinamento (**??**). Além disso, esses modelos estão sujeitos ao fenômeno de alucinação, definido como a geração de conteúdo plausível, porém não factual, podendo se manifestar tanto como divergência em relação a fatos verificáveis do mundo real quanto como inconsistência em relação à entrada fornecida pelo usuário (**??**).

2 Fundamentação Teórica

Este capítulo tem como objetivo apresentar os principais conceitos relacionados à temática deste trabalho, abordando aspectos de Inteligência Artificial, LLMs, RAG, grafos e GraphRAG, bem como sua relação com o apoio à tomada de decisão.

2.1 Modelos de Linguagem de Grande Escala (LLMs)

Os Modelos de Linguagem de Grande Escala (*Large Language Models* — LLMs) são modelos de inteligência artificial desenvolvidos para processar, compreender e gerar textos em linguagem natural (**??**).

Esses modelos são treinados a partir de grandes quantidades de dados textuais, que podem incluir livros, artigos, páginas da Web, documentos e outros tipos de conteúdo (**??**).

Durante o treinamento, técnicas de aprendizado de máquina, especialmente redes neurais profundas, são utilizadas para identificar padrões e aprender representações hierárquicas cada vez mais abstratas presentes nos dados (**??**), permitindo que o modelo aprenda características da linguagem e as relações entre os elementos textuais de acordo com os diferentes contextos em que são utilizados (**??**).

Grande parte dos LLMs modernos utiliza a arquitetura Transformer, que possibilita o processamento das relações entre diferentes elementos de uma sequência textual por meio do mecanismo de atenção (**??**).

Após o treinamento, os LLMs são capazes de processar entradas textuais, considerar o contexto fornecido e gerar respostas e novos conteúdos em linguagem natural (**??**). Essas características possibilitam sua utilização em diferentes tarefas, como resposta a perguntas, geração e sumarização de textos, tradução e outras atividades relacionadas ao processamento de linguagem natural (**??**).

Embora Shao et al. (**??**) destaquem o rápido progresso técnico dos LLMs, Bender et al. (**??**) questionam esse entusiasmo, argumentando que esses modelos funcionam como reconhecedores estatísticos de padrões linguísticos, capazes de gerar texto fluente sem compreensão genuína da linguagem, distinção relevante para este estudo, já que sistemas de apoio à decisão exigem confiabilidade semântica, não apenas fluência textual.

2.2 Retrieval-Augmented Generation (RAG)

Para mitigar as limitações de memória puramente paramétrica, Lewis et al. (2020) propõem o paradigma de Retrieval-Augmented Generation (RAG), que combina um modelo generativo pré-treinado (memória paramétrica) com uma memória não paramétrica, ou seja, um índice vetorial denso construído sobre uma base de documentos externa, acessado por um recuperador neural pré-treinado (Dense Passage Retriever). Na formulação original, o documento recuperado é tratado como uma variável latente marginalizada durante a geração, havendo duas variantes: RAG-Sequence, que condiciona toda a sequência gerada a um único documento recuperado, e RAG-Token, que permite selecionar documentos diferentes a cada token gerado. Os autores demonstram que esse acoplamento produz respostas mais específicas, diversas e factuais do que modelos puramente paramétricos, além de permitir a atualização do conhecimento do modelo pela simples substituição do índice de documentos, sem necessidade de retreinamento, o que resulta em uma vantagem central para aplicações de apoio à decisão, em que a informação precisa estar atualizada e ser auditável.

A partir dessa proposta inicial, o campo evoluiu rapidamente. Gao et al. (2023/2024), em uma revisão abrangente de mais de 100 estudos, organizam essa evolução em três paradigmas sucessivos:

- Naive RAG: o fluxo clássico de indexação (chunking + embeddings), recuperação por similaridade vetorial e geração, o chamado ”RetrieveRead”.
- Advanced RAG: introduz otimizações de pré-recuperação (reescrita e expansão de consultas, indexação estruturada/hierárquica) e pósrecuperação (reranking, compressão de contexto), buscando mitigar problemas de precisão/recall e o efeito ”lost in the middle”.
- Modular RAG: arquitetura mais flexível, com módulos substituíveis (roteamento, memória, recuperação adaptativa/iterativa/recursiva) e fluxos não sequenciais, permitindo estratégias como Self-RAG e FLARE.

Esse mesmo trabalho evidencia uma limitação estrutural crítica do RAG baseado em recuperação de chunks de texto: ele é eficaz para perguntas cuja resposta está localizada em um pequeno conjunto de registros, mas falha em tarefas de sensemaking global, isto é, perguntas que exigem uma compreensão holística de todo o corpus (ex.: ”quais são os principais temas do conjunto de dados?”). Essa lacuna, já quando o RAG tradicional lida mal com síntese multi-documento e raciocínio relacional complexo, é exatamente o ponto de partida teórico para o GraphRAG.

2.3 Grafos e Grafos de Conhecimento

Esta seção detalha os fundamentos teóricos de grafos e Grafos de Conhecimento, retomando de forma mais aprofundada o que foi introduzido brevemente na seção anterior, já que essa estrutura de representação é o elemento central que distingue o GraphRAG do RAG vetorial tradicional.

2.3.1 Fundamentos de teoria de grafos

Um grafo é formalmente definido como um par ordenado G = (V, E), em que V é um conjunto de vértices (ou nós) e E é um conjunto de arestas que conectam pares de vértices. Grafos podem ser direcionados (as arestas têm uma orientação, indicando, por exemplo, que uma entidade A afeta uma entidade B, mas não necessariamente o contrário) ou não direcionados; podem ainda ser ponderados, quando cada aresta carrega um valor numérico que representa a força ou a frequência da relação entre dois nós, um recurso explorado diretamente no GraphRAG, em que o número de vezes que uma relação é extraída de diferentes trechos do corpus é usado como peso da aresta correspondente (Edge et al., 2024).

Um conceito de teoria de grafos particularmente relevante para o GraphRAG é o de modularidade e detecção de comunidades (Newman, 2006). Uma comunidade, nesse contexto, é um subconjunto de nós mais densamente conectados entre si do que com o restante do grafo, ou seja, um agrupamento que reflete algum tipo de coesão temática ou estrutural nos dados. Algoritmos de detecção de comunidades, como o algoritmo de Leiden (Traag et al., 2019), evolução do algoritmo de Louvain (Blondel et al., 2008) que garante comunidades bem conectadas, particionam o grafo em grupos de nós fortemente relacionados, podendo fazer isso de forma hierárquica e recursiva: comunidades maiores no nível mais alto (raiz) são subdivididas em subcomunidades progressivamente menores e mais granulares em níveis inferiores. É exatamente esse mecanismo que o GraphRAG utiliza para transformar um grafo de entidades extraído de um corpus textual em uma hierarquia de sumários, de resoluções cada vez mais finas, permitindo que perguntas de diferentes níveis de abrangência sejam respondidas com o nível de granularidade apropriado.

2.3.2 Grafos de Conhecimento: definição e componentes

Um Grafo de Conhecimento (Knowledge Graph, KG) é uma aplicação específica da teoria de grafos para representar conhecimento de forma estruturada e semanticamente explícita. Hogan et al. (2021), em revisão publicada na ACM Computing Surveys, definem um KG como um grafo de dados enriquecido com semântica, no qual:

Entidades (nós) representam objetos do mundo real ou conceitos, pessoas, organizações, lugares, eventos, produtos etc.; Relações (arestas) representam conexões semânticas entre entidades, por exemplo, ”trabalha em”, ”é subsidiária de”, ”ocorreu em”; Atributos são propriedades descritivas associadas a nós ou arestas, como datas, descrições textuais ou identificadores.

Diferentemente de uma base de dados relacional tradicional, um KG não impõe um esquema rígido predefinido: novas entidades e tipos de relação podem ser incorporados de forma incremental, o que o torna particularmente adequado para representar conhecimento extraído automaticamente de texto não estruturado, como é o caso do pipeline de indexação do GraphRAG.

2.3.3 Construção de Grafos de Conhecimento a partir de texto

A construção de um KG a partir de corpora textuais envolve tradicionalmente duas tarefas centrais de extração de informação:

Reconhecimento de Entidades Nomeadas (Named Entity Recognition, NER): identificação de menções a entidades no texto e sua classificação em categorias (pessoa, organização, local etc.); Extração de Relações (Relation Extraction): identificação de conexões semânticas entre as entidades identificadas.

Historicamente, essas tarefas foram abordadas por métodos baseados em regras linguísticas, reconhecimento estatístico de padrões e, mais recentemente, por modelos de aprendizado profundo supervisionados. Com o advento dos LLMs, uma nova abordagem se consolidou: usar o próprio modelo de linguagem, por meio de prompts bem projetados, para extrair entidades, relações e afirmações factuais (claims) diretamente do texto, sem necessidade de treinamento supervisionado específico para a tarefa. É essa a abordagem adotada pelo GraphRAG: o LLM é instruído, por meio de um prompt multi-etapas, a identificar entidades com suas descrições e, em seguida, identificar pares de entidades claramente relacionadas, atribuindo uma descrição textual e uma força numérica à relação (Edge et al., 2024). Esse processo é ainda refinado por uma técnica de autorreflexão (self-reflection), em que o LLM avalia se extraiu todas as entidades relevantes de um trecho e é reincitado a capturar eventuais omissões, mitigando a perda de recall observada quando se usam trechos de texto maiores para reduzir custo computacional.

Um desafio relevante nessa etapa é a resolução de entidades (entity resolution ou entity matching): diferentes menções textuais podem se referir à mesma entidade do mundo real (por exemplo, ”Microsoft”e ”MSFT”), exigindo técnicas de reconciliação para evitar duplicação de nós no grafo final. O survey de Gao et al. (2023) também situa os KGs como uma das fontes de recuperação possíveis em sistemas RAG, ao lado de dados não estruturados (texto) e semiestruturados (tabelas, PDFs), desta-

cando que dados estruturados como KGs são tipicamente mais verificados e precisos, embora exijam maior esforço de construção, validação e manutenção.

2.3.4 Grafos de Conhecimento como índice para recuperação aumentada

A integração entre KGs e sistemas RAG segue diferentes estratégias na literatura. Algumas abordagens utilizam subgrafos ou propriedades estruturais do grafo diretamente no prompt do LLM como fundamentação factual da resposta; outras usam o grafo para orientar dinamicamente o processo de recuperação, com um agente baseado em LLM navegando pelo grafo em tempo de consulta (Gao et al., 2023). O GraphRAG se diferencia dessas abordagens ao explorar uma propriedade estrutural específica dos grafos, sua modularidade inerente, para gerar sumários hierárquicos pré-computados em tempo de indexação, que depois são combinados em um processo de map-reduce em tempo de consulta. Essa escolha de projeto é o que permite ao GraphRAG responder a perguntas de sensemaking global sem precisar percorrer o grafo inteiro a cada consulta, equilibrando custo computacional e abrangência da resposta, o ponto de conexão direto com a discussão sobre RAG feita na seção anterior.

2.4 GraphRAG

Como alternativa à representação puramente vetorial de fragmentos de texto, Grafos de Conhecimento (Knowledge Graphs, KGs) representam entidades como nós e relações semânticas entre elas como arestas, permitindo capturar explicitamente estruturas relacionais que a busca por similaridade vetorial tende a ”achatar”e perder (Hogan et al., 2021). Essa capacidade de preservar conexões entre conceitos é particularmente relevante para tarefas de raciocínio multi-hop e para a agregação de informação dispersa em múltiplos documentos, exatamente o tipo de tarefa em que o RAG tradicional apresenta fragilidades, conforme discutido acima.

O GraphRAG, proposto por Edge et al. (2024, Microsoft Research), integra a construção de um grafo de conhecimento ao pipeline de RAG para resolver especificamente o problema de query-focused summarization em nível global. A abordagem funciona em duas fases:

1. Fase de indexação: um LLM extrai entidades, relações e afirmações (claims) de cada trecho do corpus, agregando-as em um grafo de entidades ponderado. Em seguida, aplica-se um algoritmo de detecção de comunidades (Leiden) de forma hierárquica e recursiva, particionando o grafo em comunidades de nós fortemente conectados em múltiplos níveis de granularidade. Para cada comunidade, em cada nível, o LLM gera um sumário em linguagem natural, de baixo

para cima, onde sumários de comunidades de nível inferior alimentam a geração de sumários de comunidades de nível superior.

2. Fase de consulta: dada uma pergunta, os sumários de comunidade (de um determinado nível hierárquico) são usados em um processo de map-reduce: cada sumário gera uma resposta parcial independentemente (etapa map), e essas respostas parciais são então combinadas e sumarizadas em uma resposta global final (etapa reduce).

Os autores avaliam o método em corpora de aproximadamente 1 milhão de tokens (transcrições de podcast e artigos de notícias), comparando o GraphRAG contra um RAG vetorial convencional (naive RAG) e contra uma sumarização direta do textofonte via map-reduce (sem grafo). Os resultados mostram que o GraphRAG supera consistentemente o RAG vetorial em abrangência (comprehensiveness) e diversidade das respostas geradas, com taxas de vitória em comparações par-a-par entre 72% e 83%, mantendo desempenho competitivo mesmo usando sumários de comunidades de nível raiz (mais econômicos, exigindo até 97% menos tokens de contexto por consulta). Essa evidência empírica é o principal argumento teórico para se investigar o GraphRAG como tecnologia de apoio a tarefas de sensemaking, categoria à qual boa parte das decisões organizacionais complexas pertence.

2.5 Apoio à tomada de decisão

No campo organizacional, Simon (1960) estrutura o processo decisório em três fases clássicas: inteligência (identificação do problema), concepção (desenho de alternativas) e escolha (seleção de uma alternativa), um modelo que segue amplamente utilizado para analisar em que ponto do ciclo decisório uma tecnologia de IA generativa oferece suporte. Turban, Sharda e Delen, em Decision Support and Business Intelligence Systems, situam a evolução dos Sistemas de Apoio à Decisão (DSS) desde sistemas baseados em regras e modelos analíticos até arquiteturas atuais que incorporam business intelligence e, mais recentemente, IA generativa.

É nesse ponto que a articulação teórica do trabalho se fecha: sistemas de apoio à decisão precisam sintetizar informação dispersa (muitas vezes textual e não estruturada), relacionar entidades e eventos, e apresentar respostas rastreáveis às suas fontes, características que o RAG tradicional atende parcialmente, mas que o GraphRAG, por sua capacidade de raciocínio relacional e síntese global sobre grandes corpora, promete atender de forma mais completa.

2.6 Trabalhos Relacionados

Nesta seção são discutidos estudos anteriores que aplicam GraphRAG em cenários de apoio à tomada de decisão. A partir dessa discussão, é possível identificar a lacuna que motiva este mapeamento sistemático da literatura.

Rawat, Witt e Lill (**??**) propõem um framework conceitual de sistema multiagente baseado em LLM (LLM-MAS) voltado à gestão de projetos de construção civil, combinando um Coordenador Central com uma memória híbrida composta por um grafo de conhecimento (implementado em Neo4j) e um banco vetorial. Os autores validam a proposta por meio de um experimento simulado de detecção de atraso logístico na entrega de materiais, no qual o sistema utiliza o grafo de conhecimento para identificar o impacto do atraso sobre atividades dependentes e gerar um alerta ao gestor.

Dindukurthi et al. (**??**), por sua vez desenvolvem um sistema de recomendação nutricional explicável baseado em GraphRAG, no qual o LLM é restrito à formatação de respostas previamente validadas por um grafo de conhecimento, sendo o ranqueamento das recomendações realizado por um algoritmo determinístico de similaridade de cosseno. O sistema foi avaliado frente a cinco abordagens de referência (incluindo um LLM sem estrutura de recuperação), utilizando métricas de recuperação de informação como NDCG@5 e Precision@5.

Niederhaus et al. (**??**) implementam e validam uma plataforma de *analytics* prescritiva baseada em GraphRAG orientado por ontologia, aplicada em um ambiente industrial real (uma fábrica inteligente). A validação foi conduzida com usuários reais ($n = 11$), comparando o tempo necessário para a resolução de problemas técnicos com e sem o uso da plataforma proposta.

Em conjunto, esses estudos apresentam diferentes aplicações do GraphRAG para apoio à tomada de decisão, envolvendo domínios como construção civil, recomendação nutricional e ambiente industrial, além de diferentes formas de construção e utilização de grafos. Não foram identificados, na literatura consultada, mapeamentos sistemáticos dedicados a essa temática, o que motiva a proposta deste trabalho.

3 Metodologia

Para a realização deste mapeamento sistemático foram adotadas as diretrizes PRISMA 2020 (PAGE et al., 2021), que auxiliam na organização e condução de revisões sistemáticas da literatura. O PRISMA consiste em um conjunto de diretrizes utilizado para orientar o planejamento e, principalmente, o relato de revisões sistemáticas e meta-análises de forma transparente e reprodutível. Dessa forma, sua utilização contribui para a organização das etapas da pesquisa e para uma apresentação mais clara e transparente do processo de identificação, seleção e análise dos estudos.

3.1 Visão da Pesquisa

O objetivo é realizar um mapeamento sistemático da literatura sobre abordagens GraphRAG utilizadas para apoio à tomada de decisão, com o objetivo de identificar, classificar e analisar as formas de construção e utilização dos grafos, as estratégias de recuperação, as estruturas de pipeline, os domínios de aplicação, as tarefas apoiadas, as métricas empregadas e as limitações reportadas na literatura. Para estruturar essa questão de pesquisa, foi utilizado o modelo PICO, conforme apresentado na Tabela 1.

Tabela 1 – Modelo PICO

Acrônimo	**Definição**	**Descrição**
P	População ou problema	Pesquisas que abordam sistemas de RAG baseados em LLM voltados a apoio à tomada de decisão.
I	Intervenção	Uso de estruturas de grafo como componente funcional na recuperação/geração de suporte à decisão.
C	Comparação	RAG convencional (vetorial) ou sistemas de apoio à decisão tradicionais sem uso de grafo.
O	Desfecho	Identificação de formas de uso do grafo para apoiar decisões, tipos de decisão suportados, área de aplicação, métricas de qualidade e limitações reportadas na literatura.

Fonte: elaborado pelos autores (2026).

Com base no modelo PICO, foram formuladas as perguntas de pesquisa que orientam este mapeamento, apresentadas na Tabela 2, juntamente com suas respectivas

motivações.

Tabela 2 – Perguntas de Pesquisa (RQs) e Motivações

Pergunta de Pesquisa	**Motivação**
RQ1. Quais abordagens baseadas em grafos têm sido empregadas em sistemas RAG para tomada de decisão?	Conhecer as abordagens baseadas em grafos empregadas em sistema RAG com apoio a tomada de decisão permite compreender quais têm sido mais utilizadas, para que finalidade cada uma se aplica e identificar tendências emergentes na área.
RQ2. Quais estratégias de recuperação são utilizadas?	Reconhecer as estratégias de recuperação utilizadas permite comparar como cada abordagem seleciona e expande o contexto relevante à decisão, servindo de base para identificar quais estratégias melhor sustentam recomendações confiáveis.
RQ3. Em quais domínios, tarefas e tipos de decisão as abordagens são aplicadas?	Saber em quais tarefas, domínios e cenários cada abordagem tem sido usada ajuda a identificar padrões de aplicação nos estudos selecionados.
RQ4. Quais características das abordagens e dos cenários favorecem ou dificultam a adoção de uma técnica GraphRAG em detrimento de RAG convencional, para apoio à tomada de decisão?	Detectar quais características das abordagens e dos cenários favorecem ou dificultam a adoção do GraphRAG apoia a escolha fundamental entre GraphRAG e RAG convencional em cada situação prática.

Fonte: elaborado pelos autores (2026).

3.2 Processo de Pesquisa

Esta seção detalha a estratégia de busca, os critérios de inclusão e exclusão, o processo de seleção dos estudos e a extração e análise dos dados.

3.2.1 Estratégia de Busca

Para a identificação dos estudos relevantes foi elaborada uma string de busca com base nos conceitos centrais relacionados ao tema do estudo, abrangendo GraphRAG, RAG, LLM/IA generativa e tomada de decisão. Para a construção da string, foram utilizados os operadores booleanos AND e OR, com o objetivo de combinar os diferentes conceitos e abranger as diferentes formas de denominação encontradas na literatura. A busca foi realizada em duas bases de dados, Scopus e IEEE Xplore. A string de busca utilizada foi a seguinte: (”GraphRAG”OR ”Graph RAG”OR ”graph-based RAG”OR ”graph retrieval-augmented generation”OR ”graph-enhanced retrieval-augmented generation”OR ”knowledge graph retrieval-augmented generation”) AND (”retrieval-augmented generation”OR ”RAG”) AND (”large language model”OR ”LLM”OR ”generative AI”) AND (”decision support”OR ”decision-making”OR ”decision making”)

3.2.2 Critérios de Inclusão e Exclusão

Os critérios de inclusão foram estabelecidos para assegurar que os estudos selecionados sejam relevantes ao tema da pesquisa, tratem diretamente de abordagens baseadas em grafos em sistemas RAG voltados ao apoio à tomada de decisão e apresentem informações suficientes para responder às questões de pesquisa propostas. Já os critérios de exclusão foram estabelecidos para eliminar estudos que apenas mencionem os temas de forma superficial, não estejam relacionados a contextos de apoio à decisão, não tragam contribuição relevante para os objetivos da revisão, ou não atendam aos requisitos mínimos de qualidade e disponibilidade do texto (conforme apresentado na Tabela 3).

Tabela 3 – Critérios de Inclusão e Exclusão

Critérios de Inclusão	
CI1	O estudo deve apresentar uma abordagem de Retrieval-Augmented Generation na qual uma estrutura de grafo desempenhe função relevante na recuperação, seleção, expansão ou organização do contexto utilizado pelo modelo de linguagem.
CI2	O estudo deve envolver geração de respostas ou conteúdo com modelos de linguagem.
CI3	O estudo deve apresentar uma abordagem, arquitetura, método, aplicação, avaliação ou análise diretamente relacionada a GraphRAG aplicada a contextos de apoio à tomada de decisão.
CI4	O texto completo deve estar disponível.
CI5	O estudo deve estar publicado em português ou inglês.
CI6	O estudo deve ter sido publicado entre 2024 e 2026.

CI7	O sistema deve gerar alguma recomendação, priorização ou avaliação que ajude alguém a decidir algo, não apenas responder um dado.
Critérios de Exclusão	
CE1	Estudos em que a tomada de decisão é citada apenas como motivação genérica de fundo, sem que o sistema descrito produza de fato uma saída voltada à decisão (recomendação, priorização, comparação de alternativas).
CE2	Trabalhos sobre knowledge graph question answering sem componente de RAG ou geração por modelo de linguagem.
CE3	Trabalhos sobre RAG exclusivamente vetorial, sem uso significativo de estruturas em grafo.
CE4	Resumos, apresentações, pôsteres, tutoriais, editoriais e materiais sem descrição técnica suficiente.
CE5	Estudos secundários, como surveys e revisões, quando a análise principal estiver restrita aos estudos primários.
CE6	Versões duplicadas do mesmo estudo.
CE7	Artigos sem revisão por pares.

Fonte: elaborado pelos autores (2026).

3.2.3 Processo de seleção dos estudos

A seleção dos estudos será conduzida pelos dois integrantes do grupo responsáveis pela etapa de busca e triagem. Cada estudo identificado será analisado de forma independente pelos dois integrantes, com base nos critérios de inclusão e exclusão previamente definidos. Em caso de divergência quanto à inclusão ou exclusão de um estudo, prevalecerá a decisão da maioria, reduzindo o viés individual na seleção. Entre os principais desafios previstos para essa etapa está a identificação de estudos com validade adequada, uma vez que grande parte da literatura sobre o tema é recente, concentrando-se principalmente a partir de 2024. Dessa forma, os critérios de inclusão e exclusão serão aplicados rigorosamente, buscando assegurar que os estudos selecionados sejam consistentes com os objetivos da revisão e possam, posteriormente, servir de base para a construção do MVP.

3.2.4 Extração e Análise de Dados

A extração de dados dos estudos incluídos será realizada por meio de uma planilha estruturada, na qual cada artigo selecionado corresponderá a um registro contendo as respostas relevantes identificadas para cada questão de pesquisa (RQ1 a RQ6). Esse

processo permitirá reunir de forma padronizada as informações relativas à abordagem empregada, à construção e representação do grafo, às estratégias de recuperação, aos domínios, tarefas e tipos de decisão apoiados, às métricas e limitações reportadas, e às características que favorecem ou desaconselham a adoção de uma técnica GraphRAG para apoio à decisão. A síntese dos dados ocorrerá por meio da comparação e do agrupamento dessas respostas entre os diferentes estudos, possibilitando identificar padrões, convergências e lacunas na literatura.

3.2.5 Síntese e Apresentação dos Resultados

3.3 Desenho do MVP

O projeto consiste em desenvolver um MVP utilizando GraphRAG para apoio à tomada de decisão. A ideia principal é organizar o conhecimento científico como uma rede de ligações entre ideias. A ferramenta deve receber uma pergunta e apresentar alternativas lado a lado, mostrando as evidências e os trechos de origem, mas sem recomendar uma escolha final, que deve ser definida pelo usuário.

3.4 Implementação

A implementação utilizará:

- **Neo4j** – banco de dados orientado a grafos;
- Um **modelo leve de embeddings**;
- **Python** como linguagem principal.

3.5 Ontologia Fixa

A ontologia fixa do projeto irá operar a partir de um esquema rígido pré-estabelecido de:

- **Nós:** Estudo, Técnica de Recuperação, Métrica de Avaliação, Limitação, etc.;
- **Arestas:** USA, APLICADO_EM, etc.

3.6 Recuperação e LLM

O embedding será usado apenas como porta de entrada, e a partir daí, a expansão ocorre caminhando pelo grafo. O LLM fica restrito apenas à etapa final para organizar as informações extraídas, garantindo a rastreabilidade das respostas geradas.

3.7 Métricas

O foco será em duas métricas principais:

- **Taxa de Fabricação** – garantir que o modelo não invente nada que não esteja nos nós;
- **Hit Rate** – filtrar os artigos corretos a serem exibidos na busca.

Para validar as entregas a cada lote, será definido um banco de 20 a 30 perguntas com respostas já conhecidas.

3.8 Arquitetura do Sistema

A arquitetura do sistema está dividida em quatro etapas:

1. **A Pergunta:** O usuário faz a pergunta na interface.
2. **O Ponto de Entrada (Embedding):** O sistema transforma a pergunta em um vetor usando um modelo de embedding leve, e busca no Neo4j um nó de entrada compatível baseado nas descrições das entidades. O embedding serve apenas para achar essa porta de entrada.
3. **A Busca no Grafo:** A partir desse nó inicial, o sistema navega pelas conexões (arestas) criadas no Neo4j fazendo uma expansão de 1 a 2 saltos. É essa travessia que recupera os estudos e os trechos de origem relevantes.
4. **A Formatação Final (LLM):** O Python pega todos os dados recuperados pelo Neo4j e os envia para o LLM. Neste momento, o LLM age apenas como um formatador: ele organiza e apresenta o que o grafo recuperou, sem criar informações novas.